Computer Vision
Dr. Mohammadi
Fall 2022
Hoorieh Sabzevari - 98412004
HW7



۱. ابتدا تصاویر را در یک سطر نمایش میدهیم. بدین صورت که در یک حلقهی for ابتدا هر تصویر را خوانده، سپس به figure خود اضافه کرده و در انتها تمام تصاویر را نمایش میدهیم.

```
# read input victoria images and show them in a row together
fig = plt.figure(figsize=(16, 16))
columns = 7
rows = 1
for i in range(1, 8):
    img = cv2.imread(f'images/victoria{i}.png')
    fig.add_subplot(rows, columns, i)
    plt.imshow(img)
    plt.axis(False)
    fig.subplots_adjust(wspace=0.05)
plt.show()
```



سپس به منظور جاگیری تصاویر کنار هم و سایز بزرگ تصاویر، سایز عکسها را کوچک کرده و لیستی از تصاویر میسازیم. با استفاده از تابع ()cv2.stitch یک پانوراما از تصاویر تهیه میکنیم.

initialize OpenCV's image sticher object and then perform the image stitching
on input images
https://www.geeksforgeeks.org/opencv-panorama-stitching/

```
images = []
for i in range(1, 8):
    image = cv2.imread(f'images/victoria{i}.png')
    images.append(image)
    images[i - 1] = cv2.resize(images[i - 1], (0,0), fx=0.4, fy=0.4)

stitchy = cv2.Stitcher.create()

(status, stitched) = stitchy.stitch(images)
```

در انتها نیز عکس ترکیبشده را نمایش میدهیم. (موزائیک تصویر)

```
# show victoria panorama
imgplot = plt.imshow(stitched)
plt.axis(False)
plt.show()
cv2.imwrite("images/stitched.png", stitched)
```



$$\mathcal{Q}_{2} = x_{1} C_{5} \theta - y_{1} S_{in} \theta$$

$$\mathcal{Q}_{2} = x_{1} S_{in} \theta + y_{1} C_{5} \theta$$

$$C_{5} t = \sum \left(x_{2}^{M} - x_{1}^{n} C_{5} \theta + y_{1}^{n} S_{in} \theta \right)^{2} + \left(y_{2}^{M} - x_{1}^{n} S_{in} \theta - y_{1}^{n} C_{5} \theta \right)^{2}$$

$$\frac{d C_{5} t}{d \theta} = \sum 2 \left(x_{2}^{n} - x_{1}^{n} C_{5} \theta + y_{1}^{n} S_{in} \theta \right) \left(x_{1}^{n} S_{in} \theta + y_{1}^{n} C_{5} \theta \right)$$

$$+ 2 \left(y_{2}^{n} - x_{1}^{n} S_{in} \theta - y_{1}^{n} C_{5} \theta \right) \left(y_{1}^{n} S_{in} \theta - x_{1}^{n} C_{5} \theta \right) = 0$$

$$\sum \left[x_{2}^{n} x_{1}^{n} S_{in} \theta - \left(x_{1}^{n} \right)^{2} S_{in} \theta C_{5} \theta + y_{1}^{n} x_{1}^{n} S_{in} \theta - y_{1}^{n} C_{5} \theta \right) + y_{1}^{n} x_{2}^{n} C_{5} \theta + y_{1}^{n} x_{2}^{n} C_{5} \theta$$

٣. ابتدا با تابع زير تصوير را سياه سفيد مي كنيم.


```
def to_grayscale(im):
    # Your code goes here.
    im_gray = cv2.cvtColor(im, cv2.COLOR_RGB2GRAY)
    return im_gray
```

سپس با تابع زیر تصویر را blur می کنیم تا فر کانسهای بالا که موردنیاز نیستند، حذف شوند. بدین منظور از فیلتر گوسی استفاده کردیم.

```
def blur(im):
    # Your code goes here.
    im_blur = cv2.GaussianBlur(im, (5,5),0)
    return im_blur
```

با استفاده از لبهیاب canny و انتخاب آستانه ی بالا و پایین مناسب، لبههای کاغذ در تصویر را پیدا می کنیم. بدلیل اینکه در این مرحله می خواهیم فقط رئوس کاغذ را پیدا کنیم، بهتر است مقدار آستانه ی بالا و پایین را جوری انتخاب کنیم که فقط لبههای کاغذ در خروجی باشند.

```
def to_edges(im):
    # Your code goes here.
    im_edges = cv2.Canny(im, 50, 300)
    return im edges
```



با استفاده از تابع زیر ابتدا threshold مناسب را پیدا کرده، سپس نقاط دور صفحه را استخراج میکنیم. به کمک تابع (cv.approxPolyDP) شکل کاغذ و نقاط رأسهای بزرگترین چهارضلعی موجود را تخمین زده و به لیست رئوسی که داریم اضافه میکنیم. در انتها لیست مختصات رئوس کاغذ را به عنوان ریترن میکنیم. پس از چاپ کردن این لیست متوجه میشویم که بیش از چهار نقطه را به عنوان رأس استخراج کرده است، لذا چون بقیهی نقاط با دقت خوبی به چهار نقطهی اول نزدیک اند، ما هم فقط چهار نقطهی اول این خروجی را به عنوان رئوس کاغذ در نظر میگیریم.

```
def find_vertices(im):
   vertices = []
   _, threshold = cv2.threshold(im, 110, 255, cv2.THRESH_BINARY)
    contours, _= cv2.findContours(threshold, cv2.RETR_TREE,
cv2.CHAIN_APPROX_SIMPLE)
   for cnt in contours :
        approx = cv2.approxPolyDP(cnt, 0.009 * cv2.arcLength(cnt, True), True)
        n = approx.ravel()
        i = 0
        for j in n:
            if(i % 2 == 0):
                x = n[i]
                y = n[i + 1]
                vertices.append((x, y))
            i = i + 1
    return vertices
```

با استفاده از تابع زیر، ابتدا رئوس را با تابع ()reorder که از پیش تعریف شده بود، مرتب می کنیم. سپس نقاط رئوس جدید را تعریف کرده و مطابق آرایه ی قبلی مرتب می کنیم. این دو آرایه را به عنوان ورودی به تابع ()cv2.getPerspectiveTransform می دهیم تا تبدیل مناسب را پیدا کند. دقت کنید که ورودی این تابع باید دو آرایه ی pp و همچنین به صورت float باشند. سپس تصویر تبدیل یافته را به کمک تابع ()cv2.wrapPerspective ریترن می کنیم. بدین صورت نقاط موجود در تصویر اولیه که ممکن بود متوازی الاضلاع هم باشند، به نقاط یک مستطیل مپ می شوند.

```
# https://www.geeksforgeeks.org/perspective-transformation-python-opencv/
def crop_out(im, vertices):
    # Your code goes here.
    vertices = reorder(np.array(vertices[0:4], np.float32))
    target = reorder(np.array([[0, 0], [0, 700], [500, 700], [500, 0]],
np.float32))
    transform = cv2.getPerspectiveTransform(vertices, target)
    return cv2.warpPerspective(im, transform, (500, 700))
```



در مرحله ی آخر برای بهبود تصویر می توانیم از کرنل sharpening استفاده کرده و لبهها را تیز تر کنیم. سپس تصویر را به فضای HSV برده و پارامتر V را به اندازهای افزایش دهیم. راه حل دیگر برای آن که بیشتر به رنگ اسکنرها نزدیک شویم این است که تصویر را با استفاده از پیدا کردن (adaptiveTreshold) باینری کنیم. یعنی جاهای روشن تر سفید و جاهای تیره کاملا مشکی شوند. سپس نویز موجود در تصویر را حذف کنیم. با استفاده از C می توان کیفیت عکس را افزایش داد تا خروجی بهتری داشته باشیم.

Deep Learning in Video Multi-Object Tracking: A Survey

Gioefe Cuparroneth, Francisco Loque Stoches^a, Sham Tabit^a, Luigi Troizno^a, Roberto Tagisaferia^a, Francisco Herrera^b

Abstract

The problem of Multiple Object Tracking (MOT) consists in following the trajectory of different objects in a sequence, usually a video. In recent year, with the rise of Deep Learning, the algorithms that provide a solution to this problem have benefited from the representational power of deep models. This paper powides a competitionise state year works that employ Deep Learning models to solve the task of MOT on single-current videos. Four main ways for works that employ Deep Learning models to solve the task of MOT on single-current videos. Four main ways in MOT algorithms are indeed, and on in-deeph review of how Deep Learning was employed in each one of these stages in MOT expected. A complete experimental comparison of the presented works on the three MOT enablings datasets is also provided, identifying a number of similarities among the top-performing methods and presenting some possible future research directions.

Krywonde: Multiple Object Tracking, Deep Learning, Video Tracking, Convolutional Neural Networks, LSTM, Reinforcement Learning.

. 1. Introduction

1. Introduction

Motified Object Tracking (MOT), also called Motil-Target Tracking (MTT), is a computer vision task that aims to making you videous in order to identify and muck objects belonging to one or more categories, such as podestrians, care, animals and inaminate objects, without oair piece hoswinder places that opportunities and number of targets. Differently from object detection algorithms, whose corput is a collection of rectangular bounding boxes identified by their coordinates, beight and withs, NiOT algorithms is hos associate attage. If to reach box thrown as a direction, is order to detininguish among intra-class objects. An example of the output of a MOT algorithm is filtustrated in figure 1. The MOT task plays an important role in computer vision, from video surveillance to automosous cars, from action recognition to crowd behaviour analysis, many of these groblems would benefit from a high-quality tracking algorithm.

White in Single Object Tracking (SOT) the appearance of the target is fixones a priori, in NOT a detection step is secessary to identify the targets, that can leave or enter the seens. The main difficulty in tracking multiple suggest simultaneously stems from the various occupious and interactions between objects, that can sometimes also have simultar appearance. Thus, simply applying SOT models directly to solve MOT leads to poor reside, often incurring in target drift and numerous ID white errors, as such models usually strangle in distinguishing between similar looking intra-class objects. A series of algorithms specifically tured to multi-target tracking have then been developed in recent years to address these issues, opether with a number of beechmark distates and competitions to ease the comparisons between the different methods.

Recently, more and more of such algorithms have started exploiting the representational power of deep learning (DL). The strength of Deep Neural Networks (DNN) resides in their ability to learn fich representations and to extract complex and ab

*Composing saller

Lond address: (Clayarran-bussa: 1: (Goole Coperone), fluqueble cas, oge, es (Practico Loque Sinches), estandrege, es
(Shaw Tabis), res landras sando; 1: (Girj Troimo), robragbarias 1: (Robert Tajislem), herreradecess, uge es (Prancico
Herris)

در اینجا کیفیت کم تصویر اصلی نیز در خروجی موثر بوده است.